

Технически университет – София
Факултет по Приложна математика и информатика

Учебна дисциплина „Планиране на експеримента“

Курсов проект: Фотоволтаична система -
показател за ефективност

София, 2026

Съдържание

1.	Въведение	3
2.	Описание на данните	4
3.	Първична обработка на данни	5
3.1	Откриване на липсващи стойности и аномалии	5
3.2	Интерполация и почистване	5
3.3	Локални филтри	5
4.	Анализ на случайния компонент	8
4.1	Хистограма и EDF	8
4.2	Сравнение с нормално разпределение	9
5.	Корелационен анализ	10
6.	Групирани и негрупирани оценки	12
6.1	Анализ на резултатите	12
7.	Моделиране и оценка на грешката	13
7.1	Модели	13
7.2	Резултати	13
8.	Стохастично прогнозиране	15
8.1	Прогноза	15
9.	Оптимизация чрез projected gradient	17
9.1	Сравнение с OLS	17
10.	Заключение	19

1. Въведение

Настоящият проект разглежда задача по анализ, моделиране и прогнозиране на времеви ред, описващ показател за ефективност на фотоволтаична система.

Използвани са данни от вариант V49, съдържащи 120 наблюдения и хоризонт за прогноза от 6 бъдещи стойности.

Основната цел на проекта е изграждане на напълно възпроизводим програмен pipeline, който включва:

- първична обработка и почистване на данните;
- анализ на случайни величини и разпределения;
- изследване на корелационни зависимости;
- статистически оценки върху групирани и негрупирани данни;
- регресионно моделиране;
- стохастично прогнозиране;
- оптимизация чрез projected gradient метод.

Проектът е реализиран изцяло програмно чрез Python и Google Colab.

2. Описание на данните

Използваните входни файлове са:

- student_data/V49_raw.csv
- student_data/V49_future.csv

Данните съдържат следните колони:

- t — времеви индекс;
- x_norm — нормализиран фактор;
- z_factor — слънчева радиация;
- y_raw — наблюдаван сигнал.

Проектът използва следните библиотеки:

- Python 3.12
- NumPy
- Pandas
- Matplotlib

Създадена е проектова структура със следните директории:

- source/
- results/

Извършени са проверки за:

- липсващи стойности;
- дублирани редове;
- монотонност на времевия индекс;
- коректен брой наблюдения.


Установено е наличие на:

- 4 липсващи стойности;
- 3 аномални точки.

3. Първична обработка на данни

3.1 Откриване на липсващи стойности и аномалии

Първоначално е построена графика на сигнала $y_{raw}(t)$. Наблюдават се липсващи стойности и локални аномалии.



За откриване на outlier-и е използван локален медианен предиктор и MAD критерий (Median Absolute Deviation).

Аномалните точки са определени чрез условието:

$$|r_t| > 6 \cdot MAD$$

където:

$$r_t = y_t - \hat{y}_t$$

3.2 Интерполация и почистване

Липсващите стойности са възстановени чрез линейна интерполация.

Outlier-ите са заменени с локално интерполирани стойности, след което е създаден почистен ред:

$$y_{clean}(t)$$

3.3 Локални филтри

Сравнени са три локални филтъра:

F(1,1)


$$\frac{1}{3}[1,1,1]$$

F(2,1)

$$\frac{1}{9}[1,2,3,2,1]$$

F(2,2)

$$\frac{1}{8}[1,2,2,2,1]$$



Филтърът F(2,1) е избран като финален, тъй като:

- премахва значителна част от шума;
- запазва основния тренд;
- не деформира локалната динамика.


Създаден е файл:

- CLEAN.csv

с колони:

- t
- x_norm
- z_factor
- y_raw
- y_clean

- is_missing
- is_outlier
- y_smooth



4. Анализ на случайния компонент

Случайният компонент е дефиниран като:

$$e_t = y_{clean}(t) - y_{smooth}(t)$$

Изчислени са:

- средна стойност;
- дисперсия;
- стандартно отклонение;
- медиана;
- квантилите;
- коефициент на вариация.


Получената средна стойност е близка до нула, което показва липса на систематично отклонение.

4.1 Хистограма и EDF

Построени са:

- хистограма;
- емпирична функция на разпределение (EDF).

Хистограмата показва приблизително симетрична форма около нулата.






4.2 Сравнение с нормално разпределение

Случайният компонент е сравнен с:

$$N(\hat{m}, \hat{s}^2)$$

Наблюдава се добро съответствие в централната област и малки отклонения в опашките.

Следователно допускането за приблизителна нормалност е разумно.



5. Корелационен анализ

Разгледана е двойката:

$$(z_t, y_{clean}(t))$$

където:

- z_t е факторът „слънчева радиация“;
- $y_{clean}(t)$ е почистеният сигнал за ефективност на фотоволтаичната система.

Целта на анализа е да се оцени дали между двата процеса съществува статистическа зависимост и дали слънчевата радиация може да бъде използвана като регресор при моделирането.

Изчислени са:

- извадкова ковариация;
- коефициент на линейна корелация на Пирсън.

Полученият коефициент е:

$$r \approx 0.96$$

което показва много силна положителна линейна зависимост между радиацията и ефективността на системата.


Това означава, че при увеличаване на стойностите на z_t се наблюдава тенденция към нарастване и на $y_{clean}(t)$. Следователно слънчевата радиация има съществен принос при обясняване на вариацията в наблюдавания сигнал.

Scatter plot-ът потвърждава наличието на почти линейна връзка между двете величини. Наблюдава се относително малко разсейване около основната тенденция, което показва добра пригодност за използване на линейни регресионни модели.

Силната корелация е и физически обоснована, тъй като при по-висока слънчева радиация фотоволтаичната система генерира по-висока ефективност и съответно по-високи стойности на наблюдавания показател.

Scatter plot-ът потвърждава наличието на почти линейна връзка между двете величини. Наблюдава се относително малко разсейване около основната тенденция, което показва добра пригодност за използване на линейни регресионни модели.

Силната корелация е и физически обоснована, тъй като при по-висока слънчева радиация фотоволтаичната система генерира по-висока ефективност и съответно по-високи стойности на наблюдавания показател.



Scatter plot-ът потвърждава наличието на почти линейна връзка между двете величини. Наблюдава се относително малко разсейване около основната тенденция, което показва добра пригодност за използване на линейни регресионни модели.

Силната корелация е и физически обоснована, тъй като при по-висока слънчева радиация фотоволтаичната система генерира по-висока ефективност и съответно по-високи стойности на наблюдавания показател.

6. Групирани и негрупирани оценки

Редът y_{clean} е разгледан като извадка от генерална съвкупност.

Изчислени са статистики за:

- негрупирани данни;
- групирани данни с 8 равни интервала.

Сравнени са:

- средна стойност;
- медиана;
- дисперсия;
- IQR;
- коефициент на вариация.

	ungrouped	grouped(8 bins)
mean	118.3120728	118.3120728
median	120.296954	117.1172015
variance	185.0039641	179.7846943
IQR	22.450572	23.04185529
CV	0.1149638909	0.1133306279

6.1 Анализ на резултатите

Средната стойност остава практически непроменена след групиране.

Дисперсията намалява леко поради загуба на вътрешногруппова вариация.

Медианата и IQR се изменят умерено, което показва, че част от локалната информация се губи при дискретизацията.

Следователно групирането води до:

- изглаждане на вариабилността;
- загуба на точна индивидуална информация.

7. Моделиране и оценка на грешката

Данните са разделени на:

- train: $t = 1..90$
- test: $t = 91..120$

Регресорите са стандартизирани чрез:

$$u_t = \frac{x_t - \bar{x}_{train}}{s_x}$$
$$v_t = \frac{z_t - \bar{z}_{train}}{s_z}$$

7.1 Модели

Модел M1

$$y_t = \beta_0 + \beta_1 u_t + \beta_2 v_t + \varepsilon_t$$

Модел M2

$$y_t = \beta_0 + \beta_1 u_t + \beta_2 v_t + \beta_3 v_t^2 + \varepsilon_t$$

Параметрите са оценени чрез метода на най-малките квадрати.

7.2 Резултати

M1

- Train RMSE: 3.5306
- Test RMSE: 3.7850


M2

- Train RMSE: 3.5241
- Test RMSE: 3.8168

Модел M2 има минимално по-добро напасване върху train данните, но по-лоша test грешка.

Това показва риск от overfitting, тъй като квадратичният член започва да напасва шум вместо реална зависимост.

Поради по-ниската test грешка и по-простата структура е избран модел M1.



8. Стохастично прогнозиране

За избрания модел M1 са дефинирани остатъците:

$$r_t = y_{clean}(t) - \hat{y}(t)$$

Върху тях е оценен AR(1) модел:

$$r_t = \phi r_{t-1} + \eta_t$$

Получените оценки са:

$$\begin{aligned}\phi &= 0.274851 \\ \sigma_\eta &= 3.414011\end{aligned}$$

Тъй като:

$$|\phi| < 1$$

процесът е стабилен.

8.1 Прогноза

Използвайки V49_future.csv, са генерирани прогнози за:

$$t = 121..126$$

95% прогнозният интервал е изчислен чрез:

$$\hat{y}_t \pm 1.96\sigma_\eta$$


Прогнозата показва:

- лек спад до $t = 124$;
- последващо възстановяване;
- нарастване към $t = 126$.

Това поведение е физически смислено за фотоволтаична система и съответства на изменението на слънчевата радиация.

Създаден е файл:

- forecast.csv



9. Оптимизация чрез projected gradient

Параметрите на M1 са преоценени чрез projected gradient метод върху критерия:

$$J(\theta) = \text{mean}((y - X\theta)^2)$$

Използвана е стартова точка:

$$\theta^{(0)} = (\bar{y}_{train}, 0, 0)$$

с ограничения:

$$\begin{aligned}\beta_0 &\in [\bar{y}_{train} - 30, \bar{y}_{train} + 30] \\ \beta_1, \beta_2 &\in [-20, 20]\end{aligned}$$

Стъпката е:

$$\rho_k = \frac{1}{k+1}$$

Алгоритъмът достига сходимост след 178 итерации.

9.1 Сравнение с OLS


Получените параметри практически съвпадат с OLS оценките:

Параметър	OLS	Projected Gradient
beta0	117.899151	117.899151
beta1	1.329417	1.329494
beta2	13.182422	13.182483

Получените грешки също са почти идентични:

- $\text{MAE} \approx 2.774$
- $\text{RMSE} \approx 3.531$
- $\text{Bias} \approx 0$

Графиката на $J(\theta_k)$ показва гладка монотонна сходимост без нестабилности.



10. Заключение

В рамките на проекта е реализиран цялостен pipeline за анализ и прогнозиране на времеви ред за фотоволтаична система.

Извършени бяха:

- почистване и изглаждане на данните;
- статистически анализ;
- корелационно изследване;
- регресионно моделиране;
- стохастично прогнозиране;
- оптимизация чрез projected gradient метод.

Получените резултати показват, че модел M1 осигурява по-добра способност за обобщение спрямо M2 и избягва overfitting.

AR(1) моделът на остатъците успешно улавя остатъчната зависимост и позволява изграждане на прогнозни интервали.

Projected gradient методът достига практически същото решение като аналитичния OLS подход, което потвърждава коректността на реализацията.

Проектът е напълно възпроизводим и изпълнява всички поставени изисквания на заданието.